

Personal Recommendation Algorithm

Main Flow

- 个性化召回算法Item2vec背景与物理意义
- Item2vec算法应用主流程
- Item2vec算法依赖model word2vec介绍

背景

- Item2item的推荐方式效果显著
- NN model的特征抽象能力
- 算法论文:ITEM2VEC: NEURAL ITEM EMBEDDING FOR COLLABORATIVE FILTERING

物理意义

- 将用户的行为序列转化成item组成的句子
- 模仿word2vec训练word embedding将item embedding


缺陷

- 用户的行为序列时序性缺失
- 用户行为序列中的item强度是无区分性的

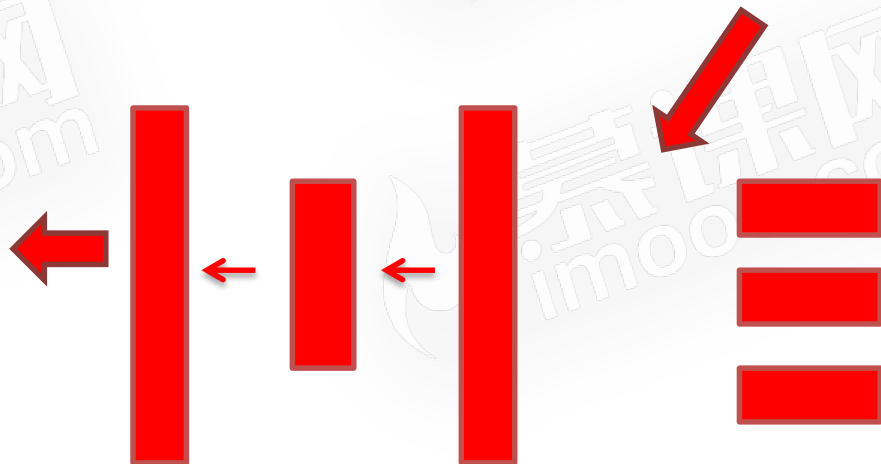
Item2vec算法主流流程

- 从log中抽取用户行为序列
- 将行为序列当成语料训练word2vec得到item embedding
- 得到item sim关系用于推荐

Example



a 0.1 0.2 0.14.....0.3
b 0.4 0.6 0.14.....0.3




Class Two



Personal Recommendation Algorithm


Word2vec Model

- CBOW (continuous bag of words)



Word2vec Model

- Skip Gram



CBOW Word2vec 数学原理

- 问题抽象

$$g(w) = \prod_{u \in w \cup NEG(w)} p(u | Context(w))$$

$$p(u | Context(w)) = \sigma(X_w^T \theta^u)^{L^w(u)} \left(1 - \sigma(X_w^T \theta^u)\right)^{(1-L^w(u))}$$

Loss Function

$$Loss = \log(g(w))$$

$$Loss = \sum \left(L^w(u) * \log(\sigma(x_w^T \theta^u)) + (1 - L^w(u)) * \log(1 - \sigma(x_w^T \theta^u)) \right)$$

梯度

$$\frac{\partial Loss}{\partial \theta^u} = \left(L^w(u) - \delta(x_w^T \theta^u) \right) x_w \quad \theta^u = \theta^u + \alpha * \frac{\partial Loss}{\partial \theta^u}$$

$$\frac{\partial Loss}{\partial x_w} = \left(L^w(u) - \delta(x_w^T \theta^u) \right) \theta^u \quad v(w_{context}) = v(w_{context}) + \sum_{u \in w \cup NEG(w)} \alpha * \frac{\partial Loss}{\partial x_w}$$

CBOW训练主流程

- 选取中心词 w 以及负采样出 $\text{NEG}(w)$
- 分别获得损失函数对于 x_w 与 θ^u 的梯度
- 更新 θ^u 以及中心词对应的 $\text{context}(w)$ 的每一个词的词向量

Class three



Personal Recommendation Algorithm

Skip Gram Word2vec 数学原理

- 问题抽象

$$G = \prod_{u \in \text{Context}(w)} \prod_{z \in u \cup \text{NEG}(u)} p(z | w)$$

$$p(z | w) = \left(\delta \left(v(w)^T \theta^z \right) \right)^{L^u(z)} * \left(1 - \delta \left(v(w)^T \theta^z \right) \right)^{1 - L^u(z)}$$

Loss Function

$$Loss = \sum_{u \in Context(w)} \sum_{z \in u \cup NEG(u)} L^u(z) * \log\left(\delta\left(v(w)^T \theta^z\right)\right) + \left(1 - L^u(z)\right) * \log\left(1 - \delta\left(v(w)^T \theta^z\right)\right)$$

$$G = \prod_{w^c \in context(w)} \prod_{u \in w \cup NEG(w)} p(u | w^c)$$

$$Loss = \sum_{w^c \in Context(w)} \sum_{u \in w \cup NEG(w)} L^w(u) * \log\left(\delta\left(v(w^c)^T \theta^u\right)\right) + \left(1 - L^w(u)\right) * \log\left(1 - \delta\left(v(w^c)^T \theta^u\right)\right)$$

Skip Gram word2vec 训练主流流程

- 对于 $\text{context}(w)$ 中任何一个词 w^c ,选取词 w 的正负样本
- 计算Loss对 θ 以及对 w^c 的偏导
- 更新 w^c 对应的词向量

负采样算法



$$\text{len}(\text{word}) = \frac{(\text{counter}(\text{word}))^\alpha}{\sum_{w \in D} (\text{counter}(w))^\alpha}$$